

# Analisis Perbandingan Algoritma Decision Tree dan Random Forest dalam Klasifikasi Konten Pelecehan Seksual pada Media Sosial

Shelma Nasywa Ramadhani Munir<sup>1</sup>, Khaira Humaira<sup>2</sup>, Khashia Arifa Zahra<sup>3</sup>, Elly Matul Imah<sup>4</sup>

<sup>1</sup>Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Negeri Surabaya, Surabaya, 60231, email: 25032014056@mhs.unesa.ac.id

<sup>2</sup>Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Negeri Surabaya, Surabaya, 60231, email: 25032014047@mhs.unesa.ac.id

<sup>3</sup>Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Negeri Surabaya, Surabaya, 60231, email: 25032014019@mhs.unesa.ac.id

<sup>4</sup>Fakultas Matematika dan Ilmu Pengetahuan Alam Universitas Negeri Surabaya, Surabaya, 60231, email: ellymatul@unesa.ac.id

Corresponding Author: Shelma Nasywa Ramadhani Munir

**INTISARI** — Penelitian ini menganalisis perbandingan kinerja algoritma *Decision Tree* dan *Random Forest* dalam mendeteksi dan mengklasifikasikan konten pelecehan seksual pada media sosial. Penyebaran konten berbasis sexism secara digital semakin meningkat seiring pertumbuhan pengguna media sosial, sehingga diperlukan sistem klasifikasi otomatis yang andal. Dataset yang digunakan adalah EXIST 2025, kumpulan data teks berlabel sexism dari media sosial yang terdiri atas enam kelas kategori. Penelitian bertujuan membandingkan *accuracy* dan *balanced accuracy* kedua model untuk menentukan pendekatan terbaik dalam mendeteksi konten sexist. Metode yang diterapkan mencakup *preprocessing* teks, ekstraksi fitur TF-IDF, pembagian data, pelatihan model, dan evaluasi performa. Hasil evaluasi menunjukkan bahwa *Decision Tree* memperoleh *accuracy* 0,3028 dan *balanced accuracy* 0,2587, sedangkan *Random Forest* memperoleh *accuracy* 0,3777 dan *balanced accuracy* 0,3478. *Random Forest* lebih unggul pada kedua metrik sehingga dinilai sebagai model terbaik untuk tugas ini. Meski demikian, akurasi kedua model masih rendah karena distribusi kelas yang tidak seimbang dan kompleksitas bahasa dalam konteks pelecehan seksual di media sosial. Penelitian ini memberikan kontribusi pada pengembangan sistem deteksi konten berbahaya yang mendukung SDG 5, yaitu Kesetaraan Gender.

**KATA KUNCI** — Decision Tree, Random Forest, Klasifikasi Teks, Pelecehan Seksual, Media Sosial, TF-IDF, EXIST 2025

## I. PENDAHULUAN

Perkembangan media sosial telah mengubah cara manusia berkomunikasi secara fundamental. Di satu sisi, platform digital mempermudah pertukaran informasi tanpa batas geografis sedangkan di sisi lain, kemudahan tersebut turut meningkatkan penyebaran konten berbahaya, termasuk konten pelecehan seksual dan sexism secara digital [1].

Konten toxic seperti hinaan verbal, pelecehan berbasis gender, dan diskriminasi seksual dapat memberikan dampak psikologis yang serius bagi korban, terutama perempuan [2].

Upaya deteksi manual terhadap konten pelecehan seksual di media sosial tidak efisien mengingat volume data yang sangat besar. Oleh karena itu, diperlukan sistem klasifikasi otomatis, yang mampu mendeteksi dan mengkategorikan konten sexist secara akurat dan efisien [3].


Penelitian ini mengusulkan perbandingan dua pendekatan machine learning, yaitu *Decision Tree* dan *Random Forest*, untuk mengklasifikasikan konten sexist dan non-sexist pada media sosial. Dataset yang digunakan adalah EXIST 2025, yaitu dataset berlabel sexism dari media sosial yang dikembangkan oleh NLP UNED Spanyol [4]. Penelitian ini juga berkontribusi pada pencapaian SDG 5 (Gender Equality) dengan mendukung terciptanya ruang digital yang lebih aman dan setara.

## II. METODE

### A. ALUR PENELITIAN

Proses klasifikasi algoritma dimulai dari blok Mulai, yang kemudian langsung menuju ke tahap pengambilan data menggunakan Dataset EXIST 2025. Setelah data dikumpulkan, langkah berikutnya adalah *Preprocessing* teks untuk membersihkan dan merapikan data teks mentah agar siap diproses. Data yang telah bersih kemudian melewati tahap Pemberian label (labeling) untuk menentukan kategori atau target prediksinya. Setelah pelabelan selesai, dilakukan

Ekstraksi fitur TF-IDF untuk mengubah teks menjadi bentuk angka (vektor numerik) berdasarkan bobot kepentingannya.



**Gambar 1.** Alur Penelitian

Setelah fitur teks berhasil diekstraksi, langkah selanjutnya adalah Split data (pemisahan data). Pada tahap ini, data dibagi menjadi dua bagian utama secara terpisah, yaitu Data Testing (yang disimpan terlebih dahulu untuk tahap pengujian akhir) dan Data Training (yang akan digunakan untuk melatih model machine learning).

Bagian Data Training kemudian dicabangkan menjadi dua jalur paralel untuk melatih dua algoritma yang berbeda. Jalur pertama masuk ke algoritma *Decision Tree*, melakukan proses Training Model, dan menghasilkan Model *Decision Tree*. Secara bersamaan, jalur kedua masuk ke algoritma *Random Forest*, melewati proses Training Model, hingga menghasilkan Model *Random Forest*.

Kedua model yang telah terlatih (Model *Decision Tree* dan Model *Random Forest*) kemudian digunakan untuk melakukan Prediksi Data Testing. Proses prediksi ini secara langsung melibatkan Data Testing yang telah dipisahkan pada tahap awal tadi (ditunjukkan oleh garis putus-putus). Hasil dari prediksi tersebut kemudian dibawa ke tahap Evaluasi performa untuk

diukur akurasi. Setelah itu, dilakukan Perbandingan *Decision Tree* dan *Random Forest* guna melihat model mana yang memiliki kinerja lebih baik. Alur pun diakhiri dengan penarikan Kesimpulan dan selesai pada blok Selesai.

## B. DATASET

Dataset exist 2025 berisi data teks dari media sosial yang telah dianotasi oleh beberapa anotator dengan latar belakang, demografis beragam. Setiap entri data mencakup *tweet*, label sexism (YES/NO), tipe sexism (DIRECT/REPORTED/JUDGEMENTAL), dan kategori sexism (IDEOLOGICAL-INEQUALITY, MISOGYNY-NON-SEXUAL-VIOLENCE, OBJECTIFICATION, SEXUAL-VIOLENCE, STEREOTYPING-DOMINANCE, NON-SEXIST, UNKNOWN).

Anotasi dilakukan oleh enam anotator per-data dengan mempertimbangkan keragaman gender, usia, latar belakang pendidikan, dan negara asal. Hal ini memastikan label yang diberikan mencerminkan perspektif yang inklusif dan representatif.

## C. PREPROCESSING TEKS

Tahap *preprocessing* teks dilakukan untuk membersihkan dan menstandarisasi data sebelum diekstraksi fiturnya. Proses ini mencakup penghapusan URL, *mention*, *hashtag*, dan karakter khusus seperti konversi teks ke huruf kecil, tokenisasi, penghapusan *stopword*, dan *stemming*.

## D. EKSTRAKSI FITUR TF-IDF

Term Frequency-Inverse Document Frequency (TF-IDF) digunakan untuk menghitung bobot setiap kata berdasarkan frekuensinya dalam dokumen dan invers frekuensinya dalam seluruh korpus, sehingga kata-kata yang informatif mendapat bobot lebih tinggi.

## E. DECISION TREE

*Decision Tree* merupakan algoritma klasifikasi yang bekerja dengan membangun pohon keputusan berdasarkan fitur-fitur data. Setiap node internal merepresentasikan pengujian terhadap suatu fitur, setiap cabang merepresentasikan hasil pengujian, dan setiap daun menyimpan label kelas. Algoritma ini mudah diinterpretasikan dan tidak memerlukan normalisasi data [3].

Untuk menentukan fitur mana yang paling efektif bertindak sebagai simpul percabangan (*node split*) dengan mengandalkan nilai matematis dari dua indikator utama, yaitu Entropi (*Entropy*) dan Keuntungan Informasi (*Information Gain*).

Indikator pertama, yaitu Entropi, merupakan sebuah ukuran statistik yang digunakan untuk menghitung derajat ketidakpastian, keacakan, atau tingkat heterogenitas di dalam sebuah ruang sampel dataset.

Pada persamaan 1 klasifikasi biner yang melibatkan dua kelas target berupa label positif ( $p$ ) dan negatif ( $n$ ), nilai entropi awal dari suatu himpunan data ( $S$ ) dihitung dengan menjumlahkan hasil perkalian negatif antara probabilitas kemunculan masing-masing kelas dengan nilai algoritma berbasis dua ( $\log_2$ ) dari probabilitas itu sendiri. Nilai entropi ini memiliki ruang mutlak antara 0 hingga 1. Batas bawah 0 menunjukkan kondisi data yang sepenuhnya homogen atau seragam karena seluruh sampel berada pada satu kelas yang sama, sedangkan batas atas 1 merepresentasikan kondisi

ketidakpastian maksimum di mana data terbagi secara seimbang dengan proporsi seimbang atau acak.

$$H(S) = - \left( \frac{p}{total} \log_2 \left( \frac{p}{total} \right) + \frac{n}{total} \log_2 \left( \frac{n}{total} \right) \right) \quad (1)$$

Indikator kedua adalah Keuntungan Informasi, yang mengukur seberapa besar penurunan tingkat ketidakpastian setelah dataset induk dipisahkan berdasarkan kategori-kategori nilai yang dimiliki oleh suatu fitur tertentu dengan menggunakan persamaan 2.

*Random Forest* merupakan pengembangan dari *Decision Tree* yang menggunakan ensemble banyak pohon keputusan. Setiap pohon dilatih dengan subset data yang diambil secara acak (*bagging*), dan keputusan akhir ditentukan berdasarkan voting mayoritas dari seluruh pohon. Pendekatan ini bertujuan mengurangi *variance* dan meningkatkan stabilitas prediksi dibandingkan *Decision Tree* tunggal [5].

## III. HASIL DAN DISKUSI

### A. HASIL PREPROCESSING DAN DISTRIBUSI DATASET

Penelitian diawali dengan memuat dataset EXIST 2025 yang berisi 6.920 entri teks dari media sosial. Selanjutnya dilakukan tahap *preprocessing* untuk membersihkan dan menormalkan data, meliputi penghapusan URL, *mention*, *hashtag*, angka, tanda baca, perubahan huruf menjadi *lowercase*, serta penyaringan *stopword* dalam bahasa Inggris dan Spanyol. Setelah proses tersebut selesai, seluruh teks berada dalam kondisi yang lebih siap untuk dianalisis. Sebanyak 50 entri dengan label UNKNOWN kemudian dihapus dari proses klasifikasi karena label tersebut tidak menunjukkan kategori sexism yang jelas. Dengan demikian, jumlah data yang digunakan pada tahap pemodelan menjadi 6.870 entri.

Distribusi label pada dataset menunjukkan adanya ketidakseimbangan antar kelas. Kelas IDEOLOGICAL-INEQUALITY merupakan kategori dengan jumlah data terbanyak, yaitu 1.562 entri, disusul STEREOTYPING-DOMINANCE sebanyak 1.528 entri dan NON-SEXIST sebanyak 1.434 entri. Sementara itu, kelas OBJECTIFICATION memiliki 1.030 entri, MISOGYNY-NON-SEXUAL-VIOLENCE sebanyak 667 entri, dan SEXUAL-VIOLENCE sebanyak 649 entri. Perbedaan jumlah antara kelas terbesar dan terkecil mencapai hampir 2,5 kali lipat. Kondisi ini menunjukkan bahwa kelas SEXUAL-VIOLENCE dan MISOGYNY-NON-SEXUAL-VIOLENCE termasuk kategori minoritas yang berisiko kurang terwakili selama proses pelatihan model.

### B. EKSTRAKSI FITUR TF-IDF

Representasi numerik teks dibentuk menggunakan metode *TF-IDF Vectorizer* dengan batas maksimum 5.000 fitur yang dipilih berdasarkan frekuensi kemunculannya. Proses ini menghasilkan matriks berukuran  $6.870 \times 5.000$ , yang berarti setiap *tweet* direpresentasikan dalam bentuk vektor numerik dengan 5.000 dimensi. Nilai pada setiap dimensi menunjukkan tingkat kepentingan suatu kata dalam sebuah *tweet* dibandingkan dengan keseluruhan dokumen pada korpus.

Jumlah fitur yang cukup besar menyebabkan matriks hasil ekstraksi memiliki karakteristik *sparse*, yaitu sebagian besar elemennya bernilai nol. Hal ini terjadi karena setiap *tweet* umumnya hanya memuat sebagian kecil dari total kosakata yang digunakan oleh model. Kondisi tersebut menjadi tantangan tersendiri bagi algoritma berbasis pohon keputusan.

Shelma Nasywa Ramdhani Munir: Analisis Decision Tree dan...

Meskipun beberapa fitur memiliki kontribusi penting pada tingkat korpus, banyak di antaranya tidak memberikan informasi yang berarti ketika dilihat pada sampel individu, sehingga proses pembentukan aturan pemisahan data menjadi lebih kompleks.

### C. PEMBAGIAN DATA DAN OVERSAMPLING

Data kemudian dibagi menjadi data *training* dan *testing* dengan rasio 80:20 menggunakan nilai *random seed* yang tetap (*seed* = 42) agar proses eksperimen dapat direproduksi. Dari total 6.870 data, sebanyak 5.496 data digunakan untuk pelatihan model, sedangkan 1.374 data sisanya digunakan untuk pengujian.

Untuk mengatasi ketidakseimbangan distribusi kelas, data *training* terlebih dahulu diproses menggunakan teknik *oversampling*. Pada tahap ini, sampel dari kelas-kelas minoritas direplikasi secara acak hingga jumlah data pada setiap kelas menjadi seimbang, yaitu masing-masing sebanyak 1.250 sampel. Setelah proses *oversampling*, jumlah data *training* meningkat menjadi 7.500 entri. Langkah ini dilakukan untuk mengurangi kecenderungan model dalam memprioritaskan kelas mayoritas selama proses pembelajaran.

Penerapan *oversampling* hanya dilakukan pada data *training*, sedangkan data *testing* dibiarkan dalam kondisi distribusi aslinya. Pendekatan ini penting untuk memastikan bahwa hasil evaluasi benar-benar menggambarkan kemampuan model ketika dihadapkan pada data yang merepresentasikan kondisi nyata, bukan data yang telah dimodifikasi untuk tujuan pelatihan.

### D. PERFORMA MODEL DECISION TREE

Model *Decision Tree* dibangun menggunakan kriteria pemisahan *Gini Impurity* dengan nilai *max\_depth* sebesar 10 dan *min\_samples\_split* sebesar 5. Setelah proses pelatihan selesai, model diuji menggunakan 1.374 data *testing*. Ringkasan hasil evaluasi model disajikan pada tabel 1, yang memuat nilai *accuracy* dan *balanced accuracy*.

TABEL I. HASIL EVALUASI MODEL DECISION TREE

| Metrik            | Nilai  |
|-------------------|--------|
| Accuracy          | 0,3028 |
| Balanced Accuracy | 0,2587 |

Hasil evaluasi menunjukkan bahwa model memperoleh akurasi sebesar 30,28%. Meskipun nilai akurasi memberikan gambaran umum mengenai performa model, analisis yang lebih mendalam dapat dilihat dari hasil prediksi pada masing-masing kelas. Model *Decision Tree* menunjukkan kecenderungan yang sangat kuat dalam memprediksi kelas *NON-SEXIST*. Hal ini terlihat dari nilai *recall* yang mencapai 0,97, yang berarti hampir seluruh data *NON-SEXIST* berhasil dikenali dengan benar. Namun, tingginya *recall* tersebut diikuti oleh nilai *precision* yang rendah, yaitu 0,27. Kondisi ini menunjukkan bahwa banyak sampel dari kelas lain juga diprediksi sebagai *NON-SEXIST*. Dengan kata lain, model cenderung memilih kelas tersebut sebagai prediksi utama karena dianggap lebih aman, suatu fenomena yang umum dikenal sebagai *majority class bias*.

Sebaliknya, kelas *OBJECTIFICATION* menunjukkan performa paling rendah. Nilai *recall* yang hanya mencapai 0,01 dan *F1-score* sebesar 0,02 mengindikasikan bahwa model

hampir tidak mampu mengenali kelas tersebut. Performa yang kurang baik juga terlihat pada kelas *MISOGYNY-NON-SEXUAL-VIOLENCE*, *SEXUAL-VIOLENCE*, dan *STEREOTYPING-DOMINANCE*, yang masing-masing memiliki nilai *recall* pada kisaran 0,12 hingga 0,18. Hasil ini menunjukkan bahwa *Decision Tree* tunggal masih mengalami kesulitan dalam membedakan kategori-kategori *sexism* yang memiliki karakteristik bahasa dan makna yang saling beririsan, sehingga batas antar kelas menjadi kurang jelas bagi model.

### E. PERFORMA MODEL RANDOM FOREST

Model *Random Forest* dibangun menggunakan 30 pohon keputusan (*n\_estimators* = 30). Parameter *max\_depth* dan *min\_samples\_split* ditetapkan sama seperti pada model *Decision Tree*, yaitu masing-masing sebesar 10 dan 5. Selain itu, jumlah fitur yang dipertimbangkan pada setiap proses pemisahan *node* dibatasi hingga 200 fitur (*max\_features* = 200). Setelah dilatih menggunakan data *training* yang telah diseimbangkan, model dievaluasi menggunakan data *testing*. Hasil evaluasi model disajikan pada tabel 2, yang memuat nilai *accuracy* dan *balanced accuracy*.

TABEL II. HASIL EVALUASI MODEL RANDOM FOREST

| Metrik            | Nilai  |
|-------------------|--------|
| Accuracy          | 0,3777 |
| Balanced Accuracy | 0,3478 |

Hasil pengujian menunjukkan bahwa *Random Forest* memberikan performa yang lebih baik dibandingkan *Decision Tree*. Akurasi model meningkat sebesar 7,5 poin persentase, sementara *balanced accuracy* mengalami peningkatan sebesar 8,9 poin persentase. Peningkatan ini menunjukkan bahwa penggunaan beberapa pohon keputusan melalui mekanisme *bagging* dan *majority voting* mampu menghasilkan prediksi yang lebih stabil dan lebih baik dalam menangani ketidakseimbangan antar kelas.

Jika dilihat per kelas, distribusi prediksi *Random Forest* juga lebih merata. Kelas *IDEOLOGICAL-INEQUALITY* memperoleh performa terbaik dengan nilai *F1-score* sebesar 0,41, yang menjadi nilai tertinggi di antara seluruh kelas pada kedua model yang diuji. Nilai tersebut didukung oleh *precision* sebesar 0,61 dan *recall* sebesar 0,30. Peningkatan yang cukup menonjol juga terlihat pada kelas *SEXUAL-VIOLENCE*, yang mencapai *F1-score* sebesar 0,35, jauh lebih tinggi dibandingkan hasil yang diperoleh *Decision Tree*.

Kelas *NON-SEXIST* masih menjadi kategori yang paling sering dikenali oleh model dengan nilai *recall* sebesar 0,85. Namun, nilai *precision*-nya meningkat menjadi 0,34, menunjukkan bahwa *Random Forest* tidak terlalu bergantung pada kelas tersebut dibandingkan *Decision Tree*. Dengan kata lain, model menjadi lebih mampu memberikan prediksi pada kelas-kelas lain tanpa terlalu sering mengelompokkannya ke dalam kategori *NON-SEXIST*.

Di sisi lain, kelas *MISOGYNY-NON-SEXUAL-VIOLENCE* menunjukkan performa yang relatif tidak banyak berubah dibandingkan model sebelumnya, dengan *F1-score* sebesar 0,28. Hasil ini mengindikasikan bahwa kategori tersebut memiliki karakteristik linguistik yang cukup mirip dengan kategori *sexism* lainnya, sehingga tetap menjadi salah satu kelas yang paling sulit dibedakan oleh kedua model.

## F. PERBANDINGAN KOMPARATIF

Perbandingan kinerja kedua model berdasarkan hasil eksperimen ditampilkan pada tabel 3 berikut:

**TABEL III.** PERBANDINGAN MODEL DECISION TREE DAN RANDOM FOREST

| Model         | Accuracy | Balanced Accuracy |
|---------------|----------|-------------------|
| Decision Tree | 0,3028   | 0,3028            |
| Random Forest | 0,3777   | 0,3478            |

Berdasarkan hasil pengujian, *Random Forest* menunjukkan performa yang lebih baik dibandingkan *Decision Tree* pada seluruh metrik evaluasi yang digunakan. Hasil ini sejalan dengan karakteristik dasar *Random Forest* yang memang dirancang untuk menangani permasalahan dengan banyak kelas, jumlah fitur yang besar, serta distribusi data yang tidak seimbang. Setiap pohon dalam model dibangun menggunakan kombinasi sampel dan fitur yang berbeda, sehingga keputusan yang dihasilkan menjadi lebih beragam. Pendekatan ini membantu mengurangi ketergantungan model pada pola tertentu dan menghasilkan prediksi yang lebih stabil.

Perbedaan hasil dengan temuan pada laporan sebelumnya kemungkinan dipengaruhi oleh perbedaan implementasi yang digunakan. Pada penelitian terdahulu, *Decision Tree* dan *Random Forest* dikembangkan secara manual menggunakan Python murni (*pure Python*), yang memiliki keterbatasan dari sisi efisiensi komputasi. Kondisi tersebut dapat menyebabkan proses pembentukan pohon tidak berjalan secara optimal, baik karena kedalaman pohon yang terbatas maupun penggunaan data pelatihan yang lebih sedikit.

Meskipun *Random Forest* memberikan hasil yang lebih baik, nilai performa yang diperoleh masih tergolong rendah. Nilai *balanced accuracy* sebesar 0,3478 menunjukkan bahwa rata-rata kemampuan model dalam mengenali setiap kelas hanya sekitar 34,8%. Angka ini masih jauh dari tingkat performa yang dapat dianggap memadai untuk diterapkan pada sistem moderasi konten otomatis.

Rendahnya performa tersebut kemungkinan dipengaruhi oleh beberapa faktor. Pertama, representasi teks menggunakan TF-IDF hanya memanfaatkan informasi mengenai kemunculan kata tanpa mempertimbangkan konteks maupun urutan kata dalam kalimat. Akibatnya, model kesulitan memahami makna yang lebih kompleks, seperti sarkasme, ironi, atau bentuk diskriminasi yang disampaikan secara tidak langsung. Kedua, meskipun ketidakseimbangan kelas telah diatasi melalui *oversampling*, metode yang digunakan hanya mereplikasi sampel yang sudah ada tanpa menghasilkan variasi data baru. Kondisi ini membuat model memperoleh lebih banyak contoh dari kelas minoritas, tetapi tidak selalu memperoleh pemahaman yang lebih baik terhadap pola bahasa yang beragam pada kelas-kelas tersebut.

## IV. KESIMPULAN

### A. KESIMPULAN

Penelitian ini berhasil merancang dan mengevaluasi *pipeline* klasifikasi teks otomatis untuk mendeteksi konten pelecehan seksual di media sosial menggunakan dataset *EXIST 2025*. Hasil eksperimen menunjukkan bahwa model *Random Forest* memberikan performa yang lebih baik dibandingkan

*Decision Tree*. *Random Forest* memperoleh nilai *accuracy* sebesar 0,3777 dan *balanced accuracy* sebesar 0,3478, sedangkan *Decision Tree* memperoleh *accuracy* sebesar 0,3028 dan *balanced accuracy* sebesar 0,2587.

Keunggulan *Random Forest* terlihat dari kemampuannya menghasilkan prediksi yang lebih merata pada berbagai kategori. Model ini mampu mengenali kelas-kelas minoritas seperti *SEXUAL-VIOLENCE* dan *IDEOLOGICAL-INEQUALITY* dengan performa yang lebih baik dibandingkan *Decision Tree*. Hasil tersebut menunjukkan bahwa pendekatan *ensemble* yang digunakan oleh *Random Forest* lebih efektif dalam menangani data teks dengan jumlah fitur yang besar dan distribusi kelas yang tidak seimbang.

Meskipun demikian, performa kedua model masih tergolong rendah. Nilai *balanced accuracy* tertinggi yang diperoleh hanya mencapai 0,3478, yang menunjukkan bahwa kemampuan model dalam mengenali seluruh kategori secara merata masih terbatas. Rendahnya performa ini dipengaruhi oleh ketidakseimbangan distribusi kelas pada dataset serta keterbatasan representasi TF-IDF yang belum mampu menangkap konteks, makna implisit, sarkasme, maupun nuansa bahasa yang sering muncul pada konten *sexism* di media sosial.

Secara keseluruhan, penelitian ini menunjukkan bahwa kombinasi TF-IDF dengan algoritma berbasis pohon keputusan dapat digunakan untuk melakukan klasifikasi enam kategori *sexism* secara otomatis. Meskipun hasil yang diperoleh belum optimal, penelitian ini dapat menjadi dasar bagi pengembangan sistem deteksi konten berbahaya yang lebih akurat pada penelitian selanjutnya.

## B. SARAN

Berdasarkan hasil penelitian yang telah dilakukan, terdapat beberapa hal yang perlu diperhatikan dalam pengembangan sistem klasifikasi konten *sexism* di masa mendatang. Penelitian selanjutnya disarankan untuk menggunakan metode representasi teks yang mampu memahami konteks kalimat secara lebih baik, mengingat TF-IDF hanya mempertimbangkan frekuensi kemunculan kata tanpa memperhatikan hubungan antar kata dalam suatu kalimat.

Selain itu, penanganan ketidakseimbangan kelas perlu dilakukan dengan teknik yang lebih efektif dibandingkan replikasi data sederhana. Penggunaan metode *oversampling* yang menghasilkan sampel sintesis berpotensi meningkatkan kemampuan model dalam mempelajari karakteristik kelas-kelas minoritas.

Penelitian berikutnya juga disarankan untuk melakukan optimasi parameter model secara lebih menyeluruh agar konfigurasi yang digunakan benar-benar sesuai dengan karakteristik data yang dianalisis. Dengan demikian, performa klasifikasi yang dihasilkan dapat meningkat secara signifikan.

## C. PENGEMBANGAN

Beberapa arah pengembangan yang dapat dilakukan pada penelitian berikutnya adalah sebagai berikut.

1. Menggunakan model bahasa kontekstual seperti BERT, RoBERTa, atau XLM-RoBERTa sebagai pengganti TF-IDF agar model dapat memahami makna kata berdasarkan konteks kalimat secara utuh.
2. Menerapkan teknik *oversampling* sintesis seperti SMOTE (*Synthetic Minority Oversampling Technique*) atau ADASYN (*Adaptive Synthetic Sampling*) untuk menghasilkan sampel baru yang lebih bervariasi pada kelas minoritas.

3. Melakukan optimasi *hyperparameter* menggunakan metode *Grid Search* atau *Random Search*, terutama pada parameter *n\_estimators*, *max\_depth*, dan *max\_features*.
4. Membandingkan performa model dengan algoritma lain yang umum digunakan dalam klasifikasi teks, seperti XGBoost, LightGBM, dan Support Vector Machine (SVM).
5. Menambahkan fitur-fitur kontekstual di luar pendekatan *bag-of-words*, seperti fitur sintaktis, skor sentimen, maupun *embedding* berbasis karakter untuk membantu model membedakan kategori yang memiliki kemiripan semantik tinggi.
6. Menguji model pada dataset yang lebih besar dan lebih beragam agar kemampuan generalisasi model dapat dievaluasi dengan lebih baik.

## REFERENSI

- [1] F. Rodríguez-Sánchez, J. Carrillo-de-Albornoz, and L. Plaza, "Automatic Classification of Sexism in Social Networks: An Empirical Study on Twitter Data," *IEEE Access*, vol. 8, pp. 219563–219576, 2020, doi: 10.1109/ACCESS.2020.3042604.
- [2] M. Iroegbu, F. O'Brien, L. C. Muñoz, dan G. Parsons, "Investigating the Psychological Impact of Cyber-Sexual Harassment," *Journal of Interpersonal Violence*, vol. 39, no. 15–16, pp. 3424–3445, 2024, doi: 10.1177/08862605241231615.
- [3] M. S. Jahan dan M. Oussalah, "A Systematic Review of Hate Speech Automatic Detection Using Natural Language Processing," *Neurocomputing*, vol. 546, art. no. 126232, 2023, doi: 10.1016/j.neucom.2023.126232.
- [4] J. Carrillo-de-Albornoz, H. Chiril, A. Fersini, E. Nozza, P. Rosso, dan M. Viviani, "EXIST 2021: sEXism Identification in Social neTworks," in *Proc. Iberian Languages Evaluation Forum (IberLEF 2021)*, CEUR Workshop Proceedings, 2021.
- [5] L. Breiman, "Random Forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001, doi: 10.1023/A:1010933404324.